BlackLegend: Sistema de Predicción del Repago de Préstamos Basado en el Perfil Financiero del Solicitante

Bryan David Molina, David Julian Penagos, Xiomara Giraldo Pérez
Departamento de Ingeniería de Sistemas
Universidad de Antioquia, Colombia

***Resumen*—*Este trabajo plantea un sistema para predecir si un préstamo será pagado, a partir de información demográfica, financiera y crediticia del solicitante y de las condiciones del préstamo. El problema se formula como una tarea de aprendizaje supervisado de clasificación binaria, con **loan_paid_back** como variable objetivo. En esta primera entrega se presentan el contexto del problema, la composición de la base de datos y su estrategia de codificación, un análisis exploratorio de los datos y una revisión del estado del arte sobre predicción de incumplimiento y* credit scoring *con aprendizaje de máquina. La salida esperada del sistema es una estimación del riesgo o de la probabilidad de repago; una posible recomendación de productos sería una etapa posterior y no hace parte de la variable objetivo del modelo.*

***Palabras clave*—*predicción de repago, riesgo crediticio,* credit scoring*, aprendizaje de máquina, clasificación binaria.*

I. DESCRIPCIÓN DEL PROBLEMA

A. Descripción del contexto del problema

En las operaciones de crédito, una decisión central consiste en estimar la probabilidad de que un solicitante cumpla sus obligaciones de pago. Una clasificación inadecuada puede aumentar las pérdidas por incumplimiento o, en el sentido contrario, producir decisiones excesivamente conservadoras que rechacen solicitantes con capacidad de pago. Por ello, el problema relevante para este proyecto es anticipar, a partir de información disponible sobre el solicitante y el préstamo, si el crédito será pagado o incumplido.

Una solución basada en aprendizaje de máquina (*Machine Learning*, ML) permite aprender patrones a partir de datos históricos etiquetados y combinar de forma sistemática variables financieras, demográficas y de historial crediticio. El modelo no busca recomendar directamente un producto bancario: su alcance es estimar el riesgo de que un préstamo no sea pagado. Esa estimación podría usarse después como insumo para decisiones de aprobación, condiciones del crédito o segmentación de clientes, pero esas decisiones quedan por fuera de la variable objetivo de este proyecto.

El conjunto de datos seleccionado es sintético. Esto facilita que el proyecto sea reproducible, pero limita la interpretación de los resultados, porque no se pueden trasladar directamente a una entidad financiera real. Por lo tanto, el desempeño obtenido debe entenderse como una evaluación de los métodos sobre este *dataset* y no como la validación de un sistema real de otorgamiento de crédito.

B. Composición y análisis exploratorio de la base de datos

Se utilizó el Loan Prediction Dataset 2025, disponible en Kaggle, que contiene 20.000 registros y 22 variables. El análisis se realizó en Python con las librerías pandas, matplotlib y scikit-learn, en un *notebook* de Jupyter disponible en el repositorio del proyecto (https://github.com/Xion07/Proyecto-modelos-y-simulaci-n-de-sistemas-2.git). En el *notebook* se verificó que no hay valores faltantes en ninguna columna ni registros duplicados, por lo que no fue necesario aplicar ninguna técnica de imputación. De las 22 variables, 21 son predictoras y una es la variable objetivo binaria. Los predictores se dividen en 15 variables numéricas y 6 categóricas:

- ***Demografía (4):*** age (entero, 21–75 años); gender (3 categorías); marital_status (4 categorías); education_level (5 categorías, incluida "Other").
- ***Información financiera (5):*** annual_income (6.000–400.000 USD); monthly_income (igual a annual_income/12); employment_status (5 categorías); debt_to_income_ratio (0,01–0,67); credit_score (373–850).
- ***Información del préstamo (6):*** loan_amount (500–49.040 USD); loan_purpose (8 categorías); interest_rate (3,1–22,5 %); loan_term (solo 36 o 60 meses); installment (cuota mensual); grade_subgrade (30 niveles, de A1 a F5).
- ***Historial crediticio (6):*** num_of_open_accounts (0–15); total_credit_limit; current_balance; delinquency_history (0–11); public_records (0–2); num_of_delinquencies (0–11).
- ***Variable objetivo (1):*** loan_paid_back, con 1 = préstamo pagado en su totalidad y 0 = incumplimiento.

Balance de clases. De los 20.000 solicitantes, 15.998 (80,0 %) pagaron el préstamo y 4.002 (20,0 %) lo incumplieron (Fig. 1). Esto significa que un clasificador que siempre prediga "pagó" tendría un *accuracy* del 80 % sin aprender nada, por lo que esa métrica por sí sola no es suficiente. Será necesario usar métricas que tengan en cuenta la clase minoritaria, como el *recall*, el F1 o el AUC-ROC; su selección definitiva se hará en la segunda entrega.

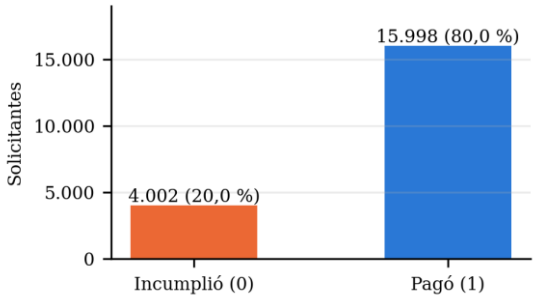


Fig. 1. Distribución de la variable objetivo loan_paid_back.

Variables numéricas. En la Tabla I se resumen las principales variables numéricas. Las variables monetarias (annual_income, total_credit_limit y current_balance) tienen una asimetría positiva fuerte, con coeficientes de 2,3; 2,5 y 2,8, por lo que conviene estandarizarlas o aplicarles una transformación logarítmica en los modelos sensibles a la escala. La variable loan_term solo toma dos valores (36 o 60 meses), así que en la práctica es binaria. En cuanto a la relación con la variable objetivo, las correlaciones lineales más altas son las de debt_to_income_ratio (r = −0,22), credit_score (r = 0,20) e interest_rate (r = −0,11), mientras que las demás están cerca de cero (Fig. 2). Una correlación lineal baja no descarta relaciones no lineales o interacciones entre variables, que los modelos basados en árboles podrían capturar mejor.

TABLA I. Estadísticos descriptivos de variables numéricas seleccionadas

Variable	Mín.	Mediana	Máx.	Media
age	21	48	75	48,0
annual_income	6.000	36.585	400.000	43.550
debt_to_income_ratio	0,01	0,16	0,67	0,18
credit_score	373	680	850	679,3
loan_amount	500	14.946	49.040	15.129
interest_rate (%)	3,14	12,40	22,51	12,40
num_of_delinquencies	0	2	11	2,49

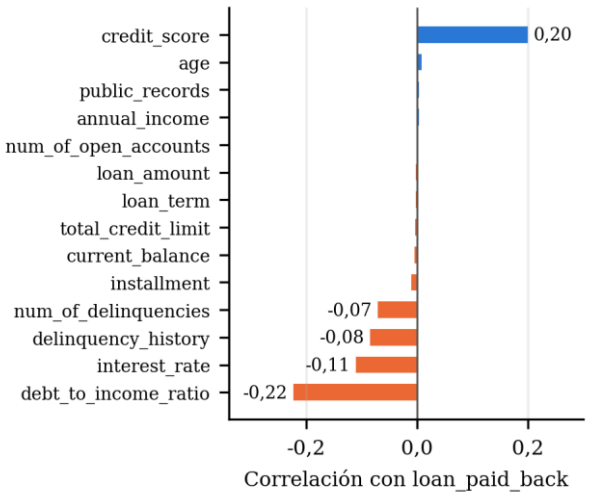


Fig. 2. Correlación de Pearson de cada variable numérica con loan_paid_back.

Variables categóricas. La variable employment_status es la que más diferencia a los grupos: solo pagaron el 18 % de los desempleados y el 41 % de los estudiantes, mientras que en los empleados y los trabajadores independientes la tasa de pago fue del 89 % y en los jubilados del 99 % (Fig. 3). En cambio, en gender, marital_status, education_level y loan_purpose las tasas de pago son muy parecidas entre categorías, todas entre el 78 % y el 83 %.

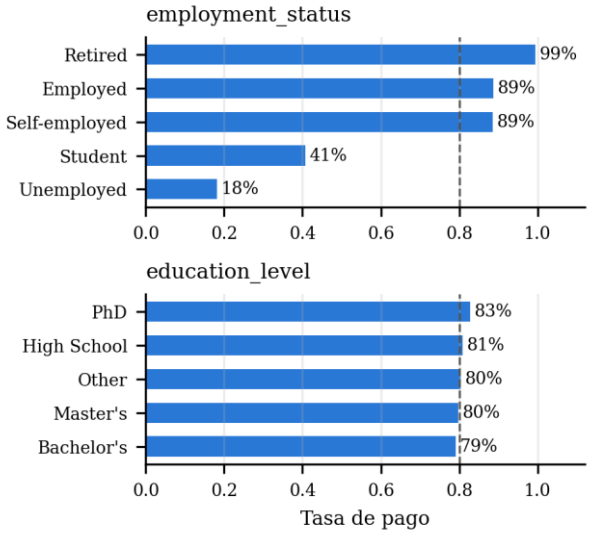


Fig. 3. Tasa de pago por categoría de employment_status y education_level. La línea punteada es la tasa global (80 %).

Redundancias y fuga de información. Se comprobó que monthly_income es exactamente annual_income dividido por 12 (la diferencia máxima es de 0,005 por redondeo y la correlación es de 1,0), así que se eliminará para evitar colinealidad perfecta. Por otro lado, grade_subgrade, interest_rate e installment son condiciones que la entidad asigna después de evaluar el riesgo del solicitante. Esto se refleja en los datos: la tasa de pago baja de forma casi monótona a medida que empeora el grado (Fig. 4) y la correlación de Spearman entre grade_subgrade e interest_rate es de 0,51. Si se usan como predictores, el modelo podría aprender una evaluación de riesgo que ya fue hecha y que no estaría disponible en el momento de decidir. Por eso se plantean dos escenarios: (A) solo con el perfil del solicitante, sin esas tres variables, que será el escenario principal, y (B) con todas las variables, como referencia del desempeño máximo que se puede alcanzar.

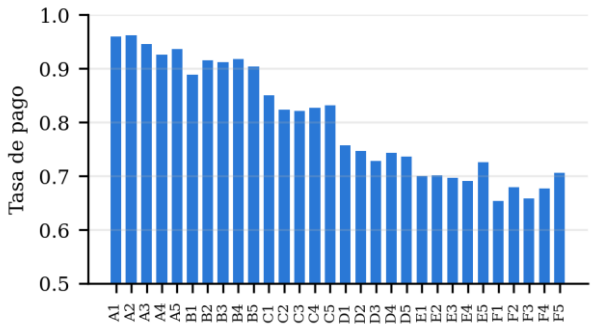


Fig. 4. Tasa de pago por grade_subgrade (de A1 a F5).

Codificación. Las variables nominales sin orden natural (gender, marital_status, employment_status y loan_purpose) se codificarán con *One-Hot Encoding*, ya que tienen pocas categorías (entre 3 y 8). La variable education_level también se codificará con *One-Hot*: aunque los niveles High School < Bachelor's < Master's < PhD tienen un orden, la categoría "Other" (1.508 registros) no se puede ubicar en esa escala. Para grade_subgrade se usará *Ordinal Encoding* (A1 = 0, …, F5 = 29), porque la tasa de pago disminuye de forma casi monótona con el grado, desde el 96 % en A1 hasta valores entre el 65 % y el 71 % en la categoría F. Las variables numéricas se dejarán en su escala original para los modelos basados en árboles y se estandarizarán dentro del *pipeline* para los algoritmos sensibles a la escala, ajustando el escalador solo con los datos de entrenamiento. Con esta codificación, el escenario A queda con 37 variables de entrada.

C. Paradigma de aprendizaje y justificación

El problema corresponde a aprendizaje supervisado de clasificación binaria: para cada observación histórica existe una etiqueta conocida, loan_paid_back, que permite aprender una función que relacione el perfil del solicitante y las características disponibles del préstamo con la probabilidad de pertenecer a la clase pago o incumplimiento. No se trata de aprendizaje no supervisado, porque el objetivo no es descubrir grupos sin etiqueta, ni de aprendizaje por refuerzo, porque no existe un proceso secuencial de acciones y recompensas.

Como línea base se usará regresión logística, por su interpretabilidad. Además, para mantener coherencia con las siguientes fases del proyecto, se evaluarán al menos un método no paramétrico (por ejemplo, k vecinos más cercanos, k-NN), un ensamble de árboles (Random Forest o Gradient Boosting/XGBoost), una máquina de vectores de soporte (SVM) y una red neuronal multicapa. La metodología de validación, la malla de hiperparámetros y las métricas de evaluación se definirán en la segunda entrega; en esta fase solo se establecen la formulación del problema y los tipos de modelos que se van a comparar.

II. ESTADO DEL ARTE

Se revisaron siete artículos de revista que abordan el mismo problema: la clasificación supervisada del riesgo de crédito o del incumplimiento. Ninguno usa el Loan Prediction Dataset 2025, pero [6] y [7] trabajan con datos de Lending Club, cuyas variables son muy parecidas a las de este proyecto.

A. Baesens et al. (2003)

Paradigma y técnica: clasificación supervisada sobre ocho bases de datos reales de *credit scoring*, comparando regresión logística, análisis discriminante, k-NN, redes neuronales, árboles de decisión, SVM y LS-SVM. *Validación y métricas: accuracy* (PCC) y AUC. *Resultados:* las LS-SVM y las redes neuronales tuvieron muy buen desempeño, aunque la regresión logística y el análisis discriminante lineal también fueron muy competitivos [1].

B. Brown y Mues (2012)

Paradigma y técnica: clasificación supervisada del incumplimiento con regresión logística, redes neuronales, C4.5, LS-SVM, Random Forest y Gradient Boosting, entre otros. *Validación y métricas:* cinco bases de datos reales en las que se aumentó el desbalance submuestreando a los morosos; AUC y pruebas de Friedman y Nemenyi. *Resultados:* Random Forest y Gradient Boosting fueron los más robustos ante desbalances fuertes, mientras que C4.5, el análisis discriminante cuadrático y k-NN fueron significativamente peores [2].

C. Addo, Guegan y Hassani (2018)

Paradigma y técnica: clasificación binaria del incumplimiento de préstamos a empresas con datos reales de un banco europeo (117.019 empresas, 1,5 % en incumplimiento y 181 variables), comparando Elastic Net, Random Forest, Gradient Boosting y cuatro redes neuronales profundas. *Validación y métricas:* 60 % de los datos para entrenamiento, 20 % para validación y 20 % para prueba, con SMOTE aplicado solo al entrenamiento; AUC y RMSE. *Resultados:* en prueba, Gradient Boosting obtuvo AUC = 0,9948 y RMSE = 0,0443, y Random Forest AUC = 0,9931, frente a 0,876 de la regresión logística. Con solo las 10 variables más importantes, los árboles se mantuvieron estables y las redes profundas no [3].

D. Chang et al. (2024)

Paradigma y técnica: clasificación supervisada del incumplimiento en clientes de tarjeta de crédito (datos de Kaggle) con regresión logística, redes neuronales, AdaBoost, Random Forest, XGBoost y LightGBM. *Validación y métricas:* partición 70/30 y datos muy desbalanceados (1,3 % de clientes malos) tratados con SMOTE; *accuracy*, precisión, *recall*, F1, ROC-AUC y MCC. *Resultados:* XGBoost fue el mejor modelo, con un *accuracy* del 99,4 % [4], aunque el conjunto de prueba reportado está balanceado (7.355 clientes buenos y 7.473 malos), lo que sugiere que SMOTE se aplicó antes de la partición y que ese valor puede estar inflado.

E. Lessmann et al. (2015)

Paradigma y técnica: comparación de 41 clasificadores (individuales y ensambles homogéneos y heterogéneos) sobre ocho bases de datos reales de *credit scoring*. *Validación y métricas:* validación cruzada N×2, con una validación interna de cinco pliegues; seis métricas: PCC, AUC, H-measure, Brier score, Gini parcial y KS. *Resultados:* varios métodos superaron significativamente a la regresión logística, y los mejores fueron los ensambles heterogéneos [5].

F. Moscato, Picariello y Sperlì (2021)

Paradigma y técnica: clasificación binaria del repago en Lending Club, comparando varios clasificadores combinados con diferentes técnicas de muestreo para tratar el desbalance. *Validación y métricas:* 877.956 préstamos y 151 atributos; AUC, sensibilidad, especificidad, G-Mean y *accuracy*.

Resultados: la mejor combinación fue Random Forest con submuestreo aleatorio (RF-RUS), con AUC = 0,717, especificidad = 0,680 y G-Mean = 0,656 [6].

G. Suhadolnik, Ueyama y Da Silva (2023)

Paradigma y técnica: comparación de diez algoritmos, desde regresión logística y k-NN hasta ensambles como XGBoost y AdaBoost, para clasificar préstamos de Lending Club como pagados o castigados. *Validación y métricas:* 1.305.402 préstamos y 18 variables tras la depuración; partición 80/20, validación cruzada de cinco pliegues y ajuste de XGBoost con RandomizedSearchCV; *accuracy*, precisión, *recall*, especificidad, F1 y AUC. *Resultados:* los ensambles, en especial XGBoost, superaron a los modelos tradicionales; en prueba, XGBoost obtuvo un *accuracy* de 0,65 y un *recall* de 0,67 para los préstamos castigados. El plazo y la tasa de interés fueron las variables más importantes [7].

H. Definición de las métricas empleadas

Las métricas básicas (*accuracy*, precisión, *recall* o sensibilidad, especificidad, F1 y AUC-ROC) se vieron en el curso; las demás se definen a continuación. VP y VN son los verdaderos positivos y negativos, FP y FN los falsos positivos y negativos (el incumplimiento es la clase positiva), $\hat{p}_i$ es la probabilidad predicha para la observación i, $y_i \in \{0, 1\}$ es su etiqueta real y N es el número de observaciones:

$$\mathrm{G-Mean} = \sqrt{\mathrm{Sensibilidad} \cdot \mathrm{Especificidad}}$$

$$\mathrm{MCC} = \frac{\mathrm{VP} \cdot \mathrm{VN} - \mathrm{FP} \cdot \mathrm{FN}}{\sqrt{(\mathrm{VP}+\mathrm{FP})(\mathrm{VP}+\mathrm{FN})(\mathrm{VN}+\mathrm{FP})(\mathrm{VN}+\mathrm{FN})}}$$

$$\mathrm{BS} = \frac{1}{N}\sum_{i=1}^{N}(\hat{p}_i - y_i)^2$$

$$\mathrm{KS} = \max_t |F_1(t) - F_0(t)|$$

En KS, F_1 y F_0 son las funciones de distribución acumulada de los puntajes de cada clase. BS es el Brier score, y el RMSE calculado sobre probabilidades equivale a $\sqrt{\mathrm{BS}}$. El coeficiente de Gini es $\mathrm{Gini} = 2 \cdot \mathrm{AUC} - 1$ y el Gini parcial lo calcula solo en una región de la curva ROC. El H-measure es una alternativa al AUC que usa una distribución de costos de error fija (una Beta), en lugar de una que depende del clasificador.

REFERENCIAS

[1] B. Baesens, T. Van Gestel, S. Viaene, M. Stepanova, J. A. K. Suykens, and J. Vanthienen, "Benchmarking state-of-the-art classification algorithms for credit scoring," Journal of the Operational Research Society, vol. 54, no. 6, pp. 627-635, 2003, doi: 10.1057/palgrave.jors.2601545.

[2] I. Brown and C. Mues, "An experimental comparison of classification algorithms for imbalanced credit scoring data sets," Expert Systems with Applications, vol. 39, no. 3, pp. 3446-3453, 2012, doi: 10.1016/j.eswa.2011.09.033.

[3] P. M. Addo, D. Guegan, and B. Hassani, "Credit Risk Analysis Using Machine and Deep Learning Models," Risks, vol. 6, no. 2, art. 38, 2018, doi: 10.3390/risks6020038.

[4] V. Chang, S. Sivakulasingam, H. Wang, S. T. Wong, M. A. Ganatra, and J. Luo, "Credit Risk Prediction Using Machine Learning and Deep Learning: A Study on Credit Card Customers," Risks, vol. 12, no. 11, art. 174, 2024, doi: 10.3390/risks12110174.

[5] S. Lessmann, B. Baesens, H.-V. Seow, and L. C. Thomas, "Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research," European Journal of Operational Research, vol. 247, no. 1, pp. 124-136, 2015, doi: 10.1016/j.ejor.2015.05.030.

[6] V. Moscato, A. Picariello, and G. Sperlì, "A benchmark of machine learning approaches for credit score prediction," Expert Systems with Applications, vol. 165, art. 113986, 2021, doi: 10.1016/j.eswa.2020.113986.

[7] N. Suhadolnik, J. Ueyama, and S. Da Silva, "Machine Learning for Enhanced Credit Risk Assessment: An Empirical Approach," Journal of Risk and Financial Management, vol. 16, no. 12, art. 496, 2023, doi: 10.3390/jrfm16120496.